

REGRESSION DATASET FOR HOUSEHOLD INCOME ANALYSIS

INTEGRANTES

José Fernando Chalo Sajquín - 22002407
Alejandra Nazareth Sosa Carrillo - 22002246
María Regina Rivas Girón - 21005971

INTRODUCCIÓN

Podar predecir el ingreso de un hogar no solo es útil desde un punto de vista económico, sino también social. Conocer con cierta precisión cuánto gana una familia permite planificar políticas públicas más efectivas, diseñar programas de asistencia focalizados y entender mejor cómo factores como la educación o el tipo de trabajo influyen en la calidad de vida.

La inteligencia artificial juega un papel clave en este tipo de problemas porque permite analizar grandes volúmenes de datos y detectar patrones que a simple vista podrían pasar desapercibidos. A través de modelos de regresión, se puede estimar el ingreso familiar tomando en cuenta diferentes características del hogar, y así obtener predicciones con un buen nivel de precisión.

El objetivo general de este proyecto es desarrollar un modelo de IA capaz de predecir los ingresos anuales de un hogar utilizando un conjunto de datos que incluye variables demográficas, laborales y sociales. El modelo debe ser capaz de identificar cuáles son las variables más influyentes y entregar predicciones útiles para posibles aplicaciones reales.

DESCRIPCIÓN DEL DATASET

Se utilizó el conjunto de datos Regression Dataset for Household Income Analysis", que contiene información diversa sobre los hogares.


Variables principales:

- Education Level:** Nivel más alto de educación alcanzado.
- Occupation:** Tipo de ocupación.
- Work Experience:** Años de experiencia laboral.
- Employment Status:** Situación laboral del miembro principal del hogar.
- Household Size:** Número total de personas que viven en el hogar.
- Annual Household Income:** Ingresos anuales reales del hogar, derivados de una combinación de características con ruido añadido.

Otras:

- Age: Edad del miembro principal del hogar.
- Location: Ubicación residencial (urbana, suburbana, rural).

CÓDIGO QR



METODOLOGÍA

Se compararon tres modelos de regresión: una red neuronal simple, un modelo de Random Forest y una red neuronal profunda construida en Keras. Este último obtuvo el mejor desempeño, por lo que se detalla a continuación.

- Preprocesamiento:** Se eliminaron valores atípicos usando el rango intercuartílico (IQR), se aplicó one-hot encoding a variables categóricas y normalización Z-score a variables numéricas.
- División de datos:** El dataset se separó en conjuntos de entrenamiento (80 %) y prueba (20 %) para evaluar el rendimiento general.
- Arquitectura del modelo:** Red neuronal con tres capas ocultas densas de 128, 64 y 32 neuronas con activación ReLU, y una capa de salida con una neurona.
- Entrenamiento:** Se utilizó el optimizador Adam, función de pérdida MSE, y métricas MAE y RMSE, además se aplicó *early stopping* para evitar sobreajuste.

RESULTADOS

La red neuronal profunda fue el modelo con mejor desempeño, logrando un MSE promedio de $7,38 \times 10^{10}$, un RMSE de $8,59 \times 10^6$ y un MAE de $4,47 \times 10^6$, superando tanto a la red neuronal simple como al modelo de Random Forest.

Entre las variables más influyentes en la predicción del ingreso destacaron el nivel educativo y el tamaño del hogar, lo cual coincide con intuiciones socioeconómicas relevantes.

El modelo demuestra potencial como herramienta de apoyo para la formulación de políticas públicas basadas en datos, orientadas a reducir desigualdades y mejorar la planificación social.

TABLA DE TODOS LOS MODELOS

Métrica	Red Simple	Red Profunda	Random Forest
MSE	$9,0 \times 10^7$	$7,4 \times 10^{10}$	$7,8 \times 10^{10}$
RMSE	$8,1 \times 10^6$	$8,6 \times 10^6$	$8,8 \times 10^6$
MAE	$5,2 \times 10^7$	$4,5 \times 10^6$	$5,3 \times 10^6$

Métricas de Evaluación por Modelo




Fig 1: Loss Function de Red Neuronal Profunda

CONCLUSIÓN

El modelo de red neuronal profunda fue el que presentó mejor desempeño entre los tres evaluados, logrando las métricas de error más bajas en la predicción del ingreso anual de los hogares. Su capacidad para capturar relaciones no lineales y complejas entre las variables lo convierte en una herramienta poderosa para este tipo de problemas de regresión.

Las métricas obtenidas reflejan una buena capacidad de generalización del modelo, con un equilibrio adecuado entre error cuadrático medio y error absoluto medio. Este rendimiento fue consistente a lo largo de distintas ejecuciones, indicando estabilidad y robustez en su comportamiento.

En cuanto al análisis de importancia de variables, se identificó que factores como el nivel educativo, el tamaño del hogar y la experiencia laboral tuvieron un impacto considerable en la predicción del ingreso. Esta correlación está en línea con intuiciones y teorías del ámbito socioeconómico, lo cual refuerza la validez del modelo en contextos reales.

En resumen, este estudio demuestra que las redes neuronales profundas no solo ofrecen precisión, sino también potencial de aplicación práctica para el diseño y evaluación de políticas públicas en temas como educación, empleo y programas sociales focalizados.

MEJORAS A FUTURO

Para fortalecer el desempeño del modelo y su aplicabilidad a gran escala, se sugiere implementar una fase más exhaustiva de ajuste de hiperparámetros, utilizando técnicas como búsqueda en cuadrícula o búsqueda bayesiana. Esto podría mejorar la capacidad predictiva y reducir aún más el margen de error.

También sería valioso incorporar nuevas variables contextuales, como indicadores regionales o acceso a servicios básicos, lo cual podría enriquecer la capacidad explicativa del modelo. El uso de técnicas de regularización más avanzadas, como early stopping más dinámico, permitiría prevenir problemas de overfitting y aumentar la generalización.

Desde una perspectiva interpretativa, integrar métodos explicativos como SHAP o LIME permitiría comprender mejor la influencia de cada variable sobre la predicción, facilitando así su uso por actores no técnicos en el ámbito de políticas públicas.

Finalmente, extender el estudio a conjuntos de datos más actualizados, con mayor diversidad geográfica o temporal, podría aumentar la validez externa del modelo y preparar el camino para su implementación en plataformas de análisis predictivo aplicadas al sector gubernamental o académico.

